

证据可追溯的公募基金 研究与组合诊断平台

离线 TF-IDF 检索、物理页 citation、模板化 Memo 与保守拒答

研究维度	固定范围
研究对象	3 只基金，2025Q3--2026Q2
官方报告	12 份季度报告
净值窗口	2024-07-24 至 2026-07-24；485 个共同实际观察日
文档语料	175 个物理页；223 个单页 chunk
检索基线	中文字符 2--4 gram TF-IDF + 余弦相似度
评测协议	10 个开发题 + 5 个一次性保留题
运行边界	本地、无外部 LLM、无 API Key、不部署

系统准确名称：可追溯文档检索与模板化投研 Memo 系统

报告日期：2026-07-27

1. 执行摘要

本项目把基金净值与公开持仓诊断、官方季度报告检索、物理页级引用、模板化 Memo 和证据不足拒答放进同一个离线系统。目标不是预测收益，而是验证研究事实能否从界面回溯到文档、页码、chunk 和哈希。

- 共同窗口内，002980 累计变化最高（154.43%），同时年化波动最高（31.41%）；003834 最大回撤最深（-28.58%）。
- 三组非对角收益相关性位于 0.774--0.891，样本期方向相关，但净值路径和披露持仓仍有差异。
- 003834 的 C10 为 51.99%—59.20%；这只说明公开前十大占 NAV 比例较高，不代表完整持仓高度集中。
- 同报告期公开前十大 CommonNAVShare 最大值为 16.55%，出现在 2025Q4 的 003834 / 002980。
- 冻结评测中开发题 10/10、保留题 5/5 端到端通过；保留题只运行一次，看到结果后没有调参。

核心边界：系统是离线 TF-IDF 检索与模板化 Memo，不是完整 LLM RAG；题集规模小，15/15 不代表任意基金开放问题上的普遍准确率。

2. 研究范围与证据链

2.1 固定研究对象

基金代码	基金名称	报告期
003567	华夏行业景气混合 A	2025Q3--2026Q2
003834	华夏能源革新股票 A	2025Q3--2026Q2
002980	华夏创新前沿股票	2025Q3--2026Q2

2.2 数据与文档处理

真实研究数据来自基金管理人官方产品页、历史净值页、公告页和季度报告 PDF。完整 PDF、完整提取文本、全量真实派生数据和原始响应只保存在本地忽略目录。

- 官方 PDF 按一基物理页提取，并清理重复页眉、页脚与断行。
- 每个 chunk 只属于一份文档和一个物理页，并保存文档、页码、chunk 与文本 SHA-256。
- F4 共处理 175 个物理页、105,426 个清理后字符，形成 223 个单页 chunk。
- F5 索引 223 个 chunk，字符 gram 词表规模为 38,033。



全流程离线；不调用 LLM、Embedding API 或外部行情接口

图 1 离线检索、证据门槛与模板化 Memo 流程

3. 净值与风险结果

净值侧固定使用累计净值；收益是相邻实际观测日简单收益，不向周末、节假日或其他缺失日填充。波动采用样本标准差（ddof=1）乘 $\sqrt{252}$ ，最大回撤保留非正符号。

共同窗口累计净值指数（起点 = 100）

指数：相邻实际观测日，不填充日历空档




图 2 三只基金共同窗口累计净值指数

代码	基金	累计变化	年化波动	最大回撤
003567	华夏行业景气混合A	130.93%	27.46%	-23.17%
003834	华夏能源革新股票A	38.41%	26.98%	-28.58%
002980	华夏创新前沿股票	154.43%	31.41%	-19.56%

表 1 共同窗口净值与风险摘要

3.1 回撤路径

共同窗口回撤路径

回撤 (%)；最大回撤保留非正符号



图 3 共同窗口回撤路径

三只基金的主要回撤阶段并不完全一致。最大回撤是样本窗口内路径统计，不用于预测未来损失，也不包含仓位穿透或实时风险。

4. 相关性与公开持仓结构

相邻观测日简单收益相关性




图 4 484 个相邻观测日简单收益的 Pearson 相关性

003567 与 002980 的相关性最高（0.891），003567 与 003834 为 0.774，003834 与 002980 为 0.778。相关性描述样本期同步程度，不表示因果关系或未来稳定性。

4.1 C10 与 HHI10




图 5 四个报告期的 C10 与 HHI10

C10 衡量公开前十大占基金 NAV 的比例；HHI10 先在十只披露持仓内部归一化再平方求和。因此，003834 的 C10 较高并不等同于其 HHI10 在每个报告期都最高。

术语边界：所有跨基金持仓比较只能称为“公开前十大持仓重合”，不能写成完整持仓重合。

5. 同报告期公开前十大持仓重合

同报告期公开前十大持仓 CommonNAVShare

共同 NAV 权重 (%)；只比较同一报告期




图 6 三组基金在同报告期的 CommonNAVShare

NameJaccard 使用披露名称精确交集除以并集；CommonNAVShare 按股票代码识别共同股票，并对每只共同股票取两只基金 NAV 权重的较小值后求和。跨基金比较严格限制在同一报告期。

- 003834 与 002980 在 2025Q4 的 CommonNAVShare 为 16.55%，是样本最大值。
- 003567 与 002980 在 2026Q2 的公开前十大没有共同股票。
- 以上结果只覆盖公开前十大，不能解释为完整组合重合或组合穿透。

6. 检索、Memo 与拒答

6.1 检索基线

用户先选择基金和报告期，系统再使用中文字符 2--4 gram TF-IDF 与余弦相似度检索。证据卡保留命中文本、分数、文档、物理页、chunk 和哈希。

6.2 双阈值证据门槛

回答必须同时满足最低最高分和最低查询 gram 覆盖率。任一门槛不足时，系统精确输出：

当前文档不足以回答该问题。

通过门槛后，Memo 固定包含“已确认事实、原文证据、研究含义、当前无法确认的内容”四段。事实部分只放入命中证据的短摘录，不能自由生成未引用结论。

6.3 为什么选择可解释基线

语料只有 12 份报告，v1 优先可解释、离线和稳定。不使用 LangChain、FAISS、外部 embedding、OpenAI API、DeepSeek API 或本地大模型。

负结果：词面检索会拒绝部分语义相关但用词不同的问题；项目选择保守拒答，不通过降低门槛掩盖这一限制。

7. 冻结评测

15 道题覆盖单文档事实、跨季度变化、跨基金比较和不可回答四类。10 个开发题用于迭代；5 个保留题在模型、阈值、题目、gold 页和评测器冻结后只执行一次。

切分	题数	端到端	Recall@5	MRR@5	引用支持	无支持主张率
开发题	10	10/10	1.00	1.00	1.00	0.00
保留题	5	5/5	1.00	1.00	1.00	0.00

表 2 开发题与一次性保留题评测

保留题锁记录 status=COMPLETED、run_count=1 和 rerun_forbidden=true。开发题与保留题的 citation support、answer completeness 和拒答正确率均为 1.0，unsupported-claim rate 为 0。

解释限制：这些结果证明冻结协议下的 15 个固定问题全部通过，不能解释为真实开放问题上的 100% 准确率。

8. 公开演示与安全边界

公开应用默认读取完全合成数据，克隆者无需网络或 API Key 即可运行净值、回撤、相关性、持仓诊断、检索、Memo 与拒答。

数据模式	默认	公开内容
demo_synthetic	是	3 只虚构基金、4 个报告期、12 份合成文档和演示索引
sample_real	否	3 只真实基金、2 个报告期、6 条不超过 110 字的短摘录
local_full	否	维护者本地研究；完整 PDF、正文和全量派生表不进入 Git

Git 候选内容审计排除 Token、凭证、完整源 PDF、私有缓存、环境变量和长篇原文。研究报告 PDF 可以公开，但 12 份官方源报告不能进入版本控制。

8.1 公开样例的版权边界

sample_real 只保留必要结构化事实、官方 URL、基金代码、报告期、物理页码和每条不超过 110 字的短摘录。原始内容权利归来源方，正式引用应返回官方页面核验。

9. 局限、负结果与结论

9.1 关键局限

- 只有 3 只同一管理人旗下基金，报告和评测样本都较小。
- 官方报告存在模板变化；未披露行业项保留为空，不用零填充。
- TF-IDF 是词面检索，可能拒绝语义相关但用词不同的问题。
- 小型真实样例不提供完整上下文；正式研究必须返回官方报告核验。
- 系统不提供实时风控、交易信号、回测、组合优化或收益预测。

9.2 结论

项目完成了从官方数据审计、结构化指标、单页 chunk、可解释检索、物理页 citation、保守拒答、冻结评测到公开离线演示的完整链路。最重要的产出不是某个模型分数，而是每个数字、引用和简历表述都有明确的结果文件、脚本、配置和数据版本。

复现入口

```
python scripts/run_pipeline.py
streamlit run app.py
reports/resume_evidence_map.md
reports/limitations.md
```